Национальный исследовательский Университет ИТМО
Мегафакультет информационных и трансляционных технологий
Факультет инфокоммуникационных технологий

Алгоритмы и структуры данных

Лабораторная работа №8

Работу выполнил:
А.Э. Филиппов
Группа: К3139
Преподаватель:
Д. Добриборщ

Санкт-Петербург
2022

Содержание

1. Задачи по варианту

1.1. Задача №3. Редакционное расстояние

Редакционное расстояние между двумя строками – это минимальное количе ство операций (вставки, удаления и замены символов) для преобразования одной строки в другую. Это мера сходства двух строк. У редакционного расстояния есть применения, например, в вычислительной биологии, обработке текстов на есте ственном языке и проверке орфографии. Ваша цель в этой задаче – вычислить расстояние редактирования между двумя строками.

- **Формат ввода / входного файла (input.txt).** Каждая из двух строк ввода содержит строку, состоящую из строчных латинских букв. Длина обеих строк - от 1 до 5000.
- **Формат вывода / выходного файла (output.txt).** Выведите расстояние ре дактирования между заданными двумя строками.
- Ограничение по времени. 2 сек.
- Ограничение по памяти. 256 мб.
- Примеры:

input.txt	output.txt	input.txt	output.txt	input.txt	output.txt
ab ab	0	shorts ports	3	editing distance	5

- Редакционное расстояние во втором примере равно 3:

s	h	o	r	t	-
-	p	o	r	t	s

Код:

```
import time
import tracemalloc

tracemalloc.start()
t_start = time.perf_counter()
file = open('input.txt')
lines = file.readlines()
out = open("output.txt", "w")

a = lines[0]
b = lines[1]

n, m = len(a), len(b)
if n > m:
    a, b = b, a
    n, m = m, n

curr_row = []
for i in range(n+1):
    curr_row.append(i)

for i in range(1, m + 1):
```

```
    prev_row, curr_row = curr_row, [i] + [0] * n
    for j in range(1, n + 1):
        move_aus_a = prev_row[j] + 1
        move_aus_b = curr_row[j-1] + 1
        fortsetzen = prev_row[j-1]
        if a[j-1] != b[i-1]:
            fortsetzen += 1
        curr_row[j] = min(move_aus_a, move_aus_b, fortsetzen)

out.write(str(curr_row[n]))

```

Для решения данной задачи использовалось расстояние Левенштайна. Вместо того, чтобы сохранять массив для ускорения работы сохраняются последняя строка и столбец.

Результат работы кода:

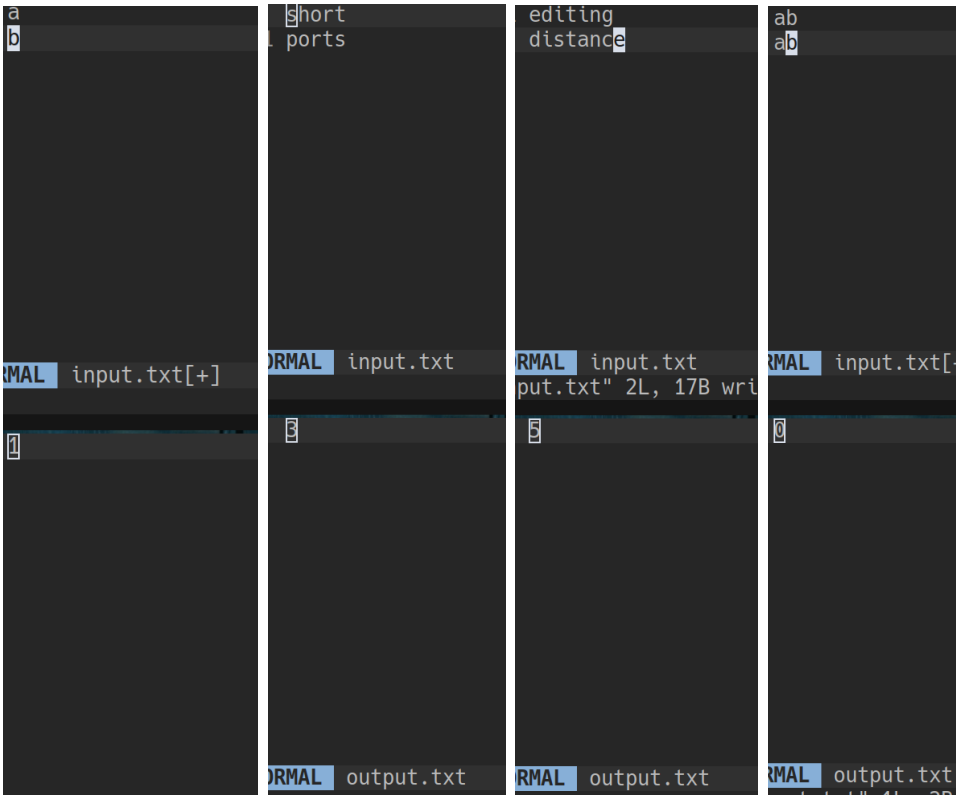

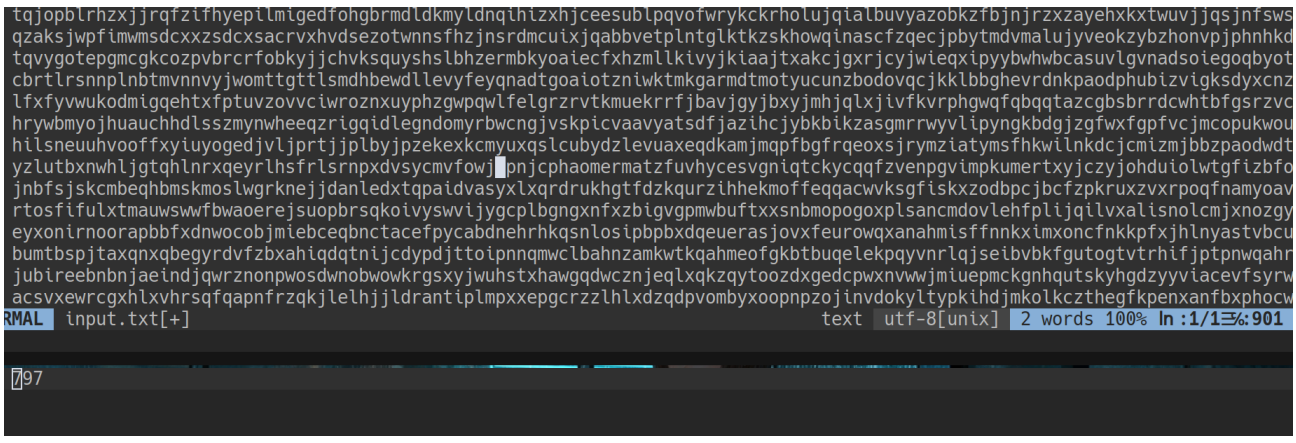

	Время выполнения (с)	Затраты памяти (байт)
Нижняя граница диапазона значений входных данных из текста задачи	0.00017152299915323965	13939
Пример из задачи 1	0.0001822340000217082	13941
Пример из задачи 2	0.00019643999985419214	13947
Пример из задачи 3	0.0002520400003049872	13952
Верхняя граница диапазона значений входных данных из текста задачи	1.9091916950001178	92904

Вывод по задаче: Расстояние Левенштайна считается самым эффективным алгоритмом для расчета редакционного расстояния. Его сложность - O(n^2)

1.2. Задача №4. Наибольшая общая подпоследовательность

Вычислить длину самой длинной общей подпоследовательности из двух по следовательностей. Даны две последовательности A = $(a_1, a_2, ..., a_n)$ и B = $(b_1, b_2, ..., b_m)$, найти длину их самой длинной общей подпоследовательности, т.е. наибольшее неотри цатеьное целое число p такое, что существуют индексы $1 \leq i_1 < i_2 < ... < i_p \leq n1 \leq j_1 < j_2 < ... < j_p \leq m$ такие, что $a_{i1} = b_{j1}, ..., a_{ip} = b_{jp}$.

- **Формат входного/выходного файла (input.txt)**
  - Первая строка n - длина первой последовательности
  - Вторая строка $a_1, a_2, ..., a_n$ через пробел
  - Третья строка m - длина второй последовательности
  - Первая строка $b_1, b_2, ..., b_m$ через пробел
- Ограничения: $1 \leq n, m \leq 100; -109 < a_i, b_i < 109$
- **Формат вывода / выходного файла (output.txt).** Выведите число
- Ограничение по времени. 1 сек.
- Примеры

input.txt	output.txt	input.txt	output.txt	input.txt	output.txt
3 2 7 5 2 2 5	2	1 7 4 1 2 3 4	0	4 2 7 8 3 4 5 2 8 7	2

- В первом примере одна общая подпоследовательность – (2, 5) длиной 2, во втором примере две последовательности не имеют одинаковых элементов. В третьем примере - длина 2, последовательности – (2, 7) или (2, 8).

Код:

```
import time
import tracemalloc

tracemalloc.start()
t_start = time.perf_counter()
file = open('input.txt')
lines = file.readlines()
out = open("output.txt", "w")

n = int(lines[0])
a = list(map(int, lines[1].split()))

m = int(lines[2])
b = list(map(int, lines[3].split()))

dp = [[None for x in range(m+1)] for i in range(n+1)]

for i in range(n+1):
    for j in range(m+1):
        if i == 0 or j == 0:
            dp[i][j] = 0
        elif a[i-1] == b[j-1]:
            dp[i][j] = dp[i-1][j-1] + 1
        else:
            dp[i][j] = max(dp[i-1][j], dp[i][j-1])

out.write(str(dp[n][m]))

print("Время выполнения: " + str(time.perf_counter() - t_start) +
 ↪  " секунд")
print("Использование памяти: " +
      str(tracemalloc.get_traced_memory()[1]) + " байт")
tracemalloc.stop()
```

Для решения данной задачи использовалась динамическая матрица. В случае если строки совпадают, то значение увеличивается на единицу, иначе берется максимум из соседней левой или соседней верхней клетки. [3]

Результат работы кода:

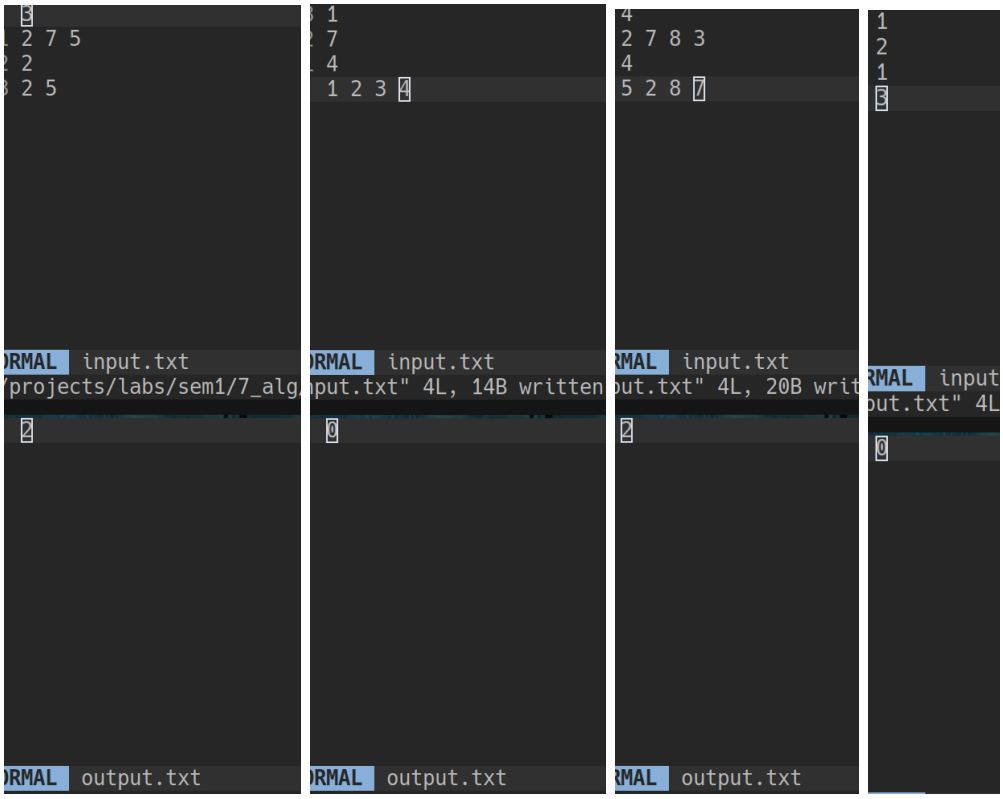
3
1 2 7 5
2 2
3 2 5
RMAL input.txt
projects/labs/sem1/7_alg
2
RMAL output.txt
1
7
4
1 2 3 4
RMAL input.txt
put.txt" 4L, 14B written
0
RMAL output.txt
4
2 7 8 3
4
5 2 8 7
RMAL input.txt
ut.txt" 4L, 20B writ
2
RMAL output.txt
1
2
1
3
RMAL input
ut.txt" 4L
0

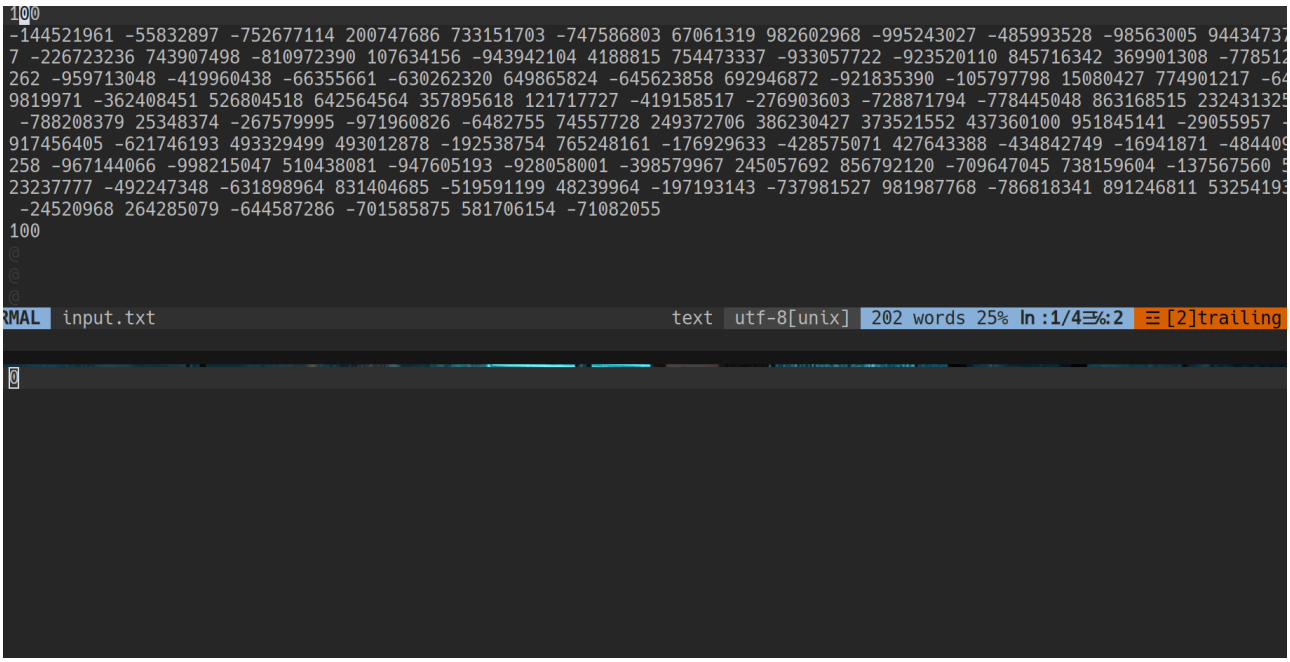
100
-144521961 -55832897 -752677114 200747686 733151703 -747586803 67061319 982602968 -995243027 -485993528 -98563005 94434737
7 -226723236 743907498 -810972390 107634156 -943942104 4188815 754473337 -933057722 -923520110 845716342 369901308 -778512
262 -959713048 -419960438 -66355661 -630262320 649865824 -645623858 692946872 -921835390 -105797798 15080427 774901217 -64
9819971 -362408451 526804518 642564564 357895618 121717727 -419158517 -276903603 -728871794 -778445048 863168515 232431325
-788208379 25348374 -267579995 -971960826 -6482755 74557728 249372706 386230427 373521552 437360100 951845141 -29055957 -
917456405 -621746193 493329499 493012878 -192538754 765248161 -176929633 -428575071 427643388 -434842749 -16941871 -484409
258 -967144066 -998215047 510438081 -947605193 -928058001 -398579967 245057692 856792120 -709647045 738159604 -137567560 5
23237777 -492247348 -631898964 831404685 -519591199 48239964 -197193143 -737981527 981987768 -786818341 891246811 53254193
-24520968 264285079 -644587286 -701585875 581706154 -71082055
100
RMAL input.txt text utf-8[unix] 202 words 25% ln :1/4☰%:2 ☲ [2]trailing
0

	Время выполнения (с)	Затраты памяти (байт)
Нижняя граница диапазона значений входных данных из текста задачи	0.00020014999972772785	14041
Пример из задачи 1	0.0002073760006169323	14047
Пример из задачи 2	0.0001917669997055782	14047
Пример из задачи 3	0.0002121620000252733	14053
Верхняя граница диапазона значений входных данных из текста задачи	0.009543416999804322	115035

Вывод по задаче: К некоторым задачам можно подходить с помощью построения динамической матрицы вместо рекурсии. Решение можно далее оптимзировать сохраняя лишь последнюю строку и столбец

Вывод

Подход динамического программирования [2] чем-то похож на модель «разделяй и властвуй». На первый взгляд сложно выделить какие-то отличия между этими двумя подходами. Отличие же заключается в том, что «разделяй и властвуй» [1] разбивает большую задачу на маленькие «сверху», а затем объединяет их в одно решение. В динамическом программировании, как правило большая задача решается «снизу», поэтому подзадачи объединяются естественнее и проще. [3]

Список использованных источников

1. *Additya Chatterjee Ue Kiao G. Z.* Decrease and Conquer Algorithms. — Independent co., 2022.
2. *BertSekas D. P.* Dynamic Programming and Optimal Control: 1. — Addison-Wesley Professional., 2017.
3. *Peter Sanders Martin Dietzfelbinger R. D.* Sequential and Parallel Algorithms and Data Structures: The Basic Toolbox. — Springer, 2019.